

## Resultados EDA univariante – variables numéricas

En las variables numéricas se observa que, en general, las distribuciones no presentan una asimetría extrema; la excepción es la edad, donde aparecen algunos valores claramente alejados del resto (**usuarios de más de 60 años**). Estos casos pueden considerarse outliers, pero también aportan información relevante sobre el comportamiento de un segmento sénior, por lo que tiene sentido **tratarlos como subgrupo específico en el análisis bivalente**, en lugar de eliminarlos.

- La variable age presenta una distribución sesgada a la derecha, con mayor concentración de usuarios en edades jóvenes y algunos valores en edades avanzadas.
- customer\_reviews\_importance muestra indicios de distribución bimodal, lo que sugiere que hay usuarios que casi no usan las reseñas y otros que les dan bastante importancia.
- rating\_accuracy y shopping\_satisfaction tienen una distribución aproximadamente simétrica y cercana a la normal, concentrada en valores medios-altos.

En términos de variabilidad:

- customer\_reviews\_importance, rating\_accuracy y shopping\_satisfaction presentan una desviación estándar relativamente baja, lo que indica poca variabilidad en la importancia atribuida a las reseñas, la precisión percibida de las valoraciones y la satisfacción general (la mayoría de usuarios se sitúan en rangos similares).
- age es la variable con mayor variabilidad, lo que permitirá analizar diferencias de comportamiento entre grupos de edad.

## Resultados EDA univariante – variables categóricas

Los recuentos y fracciones de las variables categóricas muestran varios patrones claros:

- **Género (gender):** la muestra está dominada por mujeres (58 %), seguida de hombres (24 %). Las categorías Prefer not to say (15 %) y Others (3 %) tienen menos peso, pero no son despreciables.
- **Frecuencia de compra (purchase\_frequency):** la categoría más frecuente es Few times a month (34 %), seguida de Less than once a month (21 %) y Once a week (19 %). Es decir, la mayoría de usuarios compra al menos mensualmente, con un grupo minoritario de usuarios muy frecuentes (Multiple times a week).
- **Frecuencia de navegación (browsing\_frequency):** predomina Few times a week (41 %), seguida de Few times a month (33 %). Solo un ~13 % navega raramente y otro 13 % lo hace Multiple times a day, lo que ofrece contraste interesante para las hipótesis sobre navegación vs completado de compra.

En cuanto a comportamiento de búsqueda y exploración:

- **Método de búsqueda (product\_search\_method):** los usuarios se reparten principalmente entre navegación por categories (37 %), búsqueda por Keyword (36 %) y uso de Filter (21 %), con un pequeño grupo en others.

- **Exploración de resultados (search\_result\_exploration):** la mayoría explora Multiple pages (73 %), mientras que solo un 27 % se queda en la First page, lo que indica disposición a comparar opciones.

En el proceso de decisión y compra:

- **Add to cart (add\_to\_cart\_browsing):** Maybe (41 %) y Yes (36 %) concentran la mayor parte de las respuestas, mientras que No representa un 23 %.
- **Completado de carrito (cart\_completion\_frequency):** la categoría dominante es Sometimes (51 %), seguida de Often (26 %). Rarely (12 %), Always (8 %) y Never (4 %) son minoritarias, lo que sugiere que el comportamiento de compra no es completamente consistente para muchos usuarios.
- **Motivos de abandono (cart\_abandonment\_factors):** los principales motivos son Found a better price elsewhere (42 %) y Changed my mind or no longer need the item (40 %); High shipping costs supone un 12 % y others un 6 %. El abandono parece estar más ligado a comparación de precios y cambios de intención que a factores puramente logísticos.

En cuanto a reseñas y recomendaciones:

- **Dejar reseña (review\_left):** la muestra está bastante equilibrada: un 52 % afirma que suele dejar reseñas y un 48 % no lo hace.
- **Confiabilidad de las reseñas (review\_reliability):** la mayoría se sitúa en niveles intermedios: Moderately (33 %) y Occasionally (32 %), seguidos de Heavily (25 %). Rarely y Never son minoritarios.
- **Utilidad percibida de las reseñas (review\_helpfulness):** Yes (40 %) y Sometimes (38 %) dominan, mientras que No representa un 23 %.
- **Utilidad de las recomendaciones personalizadas (recommendation\_helpfulness):** la respuesta más frecuente es Sometimes (45 %), seguida de No (29 %) y Yes (26 %), lo que indica cierto escepticismo hacia las recomendaciones automáticas.

Por último, en cuanto a **percepción del servicio**:

- **Aspecto más apreciado (service\_appreciation):** destacan Product recommendations (31 %), Competitive prices (30 %) y Wide product selection (25 %). Otros motivos como User-friendly website/app interface tienen menor peso pero siguen siendo relevantes.
- **Áreas de mejora (improvement\_areas):** los usuarios señalan principalmente Customer service responsiveness (36 %), Product quality and accuracy (27 %) y Reducing packaging waste (22 %), seguidos de Shipping speed and reliability (13 %).

### **Preparación del dataset para el EDA bivalente y multivariante**

A partir del EDA univariante se ha construido un **dataset preparado** para el análisis bivalente y multivariante, exportado como amazon\_client\_behavior\_prepared.csv. Este fichero incluye:

- Todas las variables originales, con nombres limpiados y tipos adecuados (fechas parseadas, numéricas convertidas a tipo numérico, categóricas a tipo categórico o string).
- Flags/dummies creadas a partir de purchase\_categories para las principales categorías de producto (buys\_beauty\_and\_personal\_care, buys\_clothing\_and\_fashion, buys\_groceries\_and\_gourmet\_food, buys\_home\_and\_kitchen, buys\_others).

Estas transformaciones permiten trabajar directamente con las hipótesis planteadas, por ejemplo:

- Relación entre edad y dependencia de reseñas (age vs customer\_reviews\_importance).
- Efecto de la frecuencia de navegación en el completado de carrito (browsing\_frequency vs cart\_completion\_frequency).
- Diferencias entre tipos de compradores según categorías de producto (flags buys\_\*) y variables de comportamiento (satisfacción, abandono, reseñas).

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Cargar el dataset preparado por el EDA univariante
df = pd.read_csv("amazon_client_behavior_prepared.csv")

# Opcional: inspección rápida
df.info()
df.head()

# Ejemplo: edad vs importancia de reseñas
sns.lmplot(
    data=df,
    x="age",
    y="customer_reviews_importance",
    lowess=True,
    scatter_kws={"alpha": 0.4}
)

# Ejemplo: frecuencia de navegación vs completado de carrito
pd.crosstab(df["browsing_frequency"], df["cart_completion_frequency"],
            normalize="index")

# Ejemplo: satisfacción según tipo de categoría comprada
sns.boxplot(
    data=df,
    x="buys_clothing_and_fashion",
    y="shopping_satisfaction"
)
```